Proyecto 2 - Clasificación de género de películas

Elaborado por: Héctor David Castro, Gabriel Bolaños, Jaime Rodriguez y José Hoyos

En este proyecto se usará un conjunto de datos de géneros de películas. Cada observación contiene el título de una película, su año de lanzamiento, la sinopsis o plot de la película (resumen de la trama) y los géneros a los que pertenece. El algoritmo predicirá la probabilidad de que una película pertenezca, dada la sinopsis, a cada uno de los géneros.

In [42]:
```
dataTraining.head()
```

Out[42]:

	year	title	plot	genres	rating
3107	2003	Most	most is the story of a single father who takes...	['Short', 'Drama']	8.0
900	2008	How to Be a Serial Killer	a serial killer decides to teach the secrets o...	['Comedy', 'Crime', 'Horror']	5.6
6724	1941	A Woman's Face	in sweden , a female blackmailer with a disfi...	['Drama', 'Film-Noir', 'Thriller']	7.2
4704	1954	Executive Suite	in a friday afternoon in new york , the presi...	['Drama']	7.4
2582	1990	Narrow Margin	in los angeles , the editor of a publishing h...	['Action', 'Crime', 'Thriller']	6.6

Preprocesamiento de datos

En el siguiente apartado vamos a preprocesar la base de datos según las técnicas vistas en el curso. Cabe resaltar que en la documentación solamente están las que dieron mejores resultados de predicción.

TFIDVectorizer + Stop words + Lematización de verbos

In [15]:
```
stop_words_ = list(set(stopwords.words('english')))

lemmatizer = WordNetLemmatizer()
def split_into_lemmas(text):
    text = text.lower()
    words = text.split()
    return [wordnet_lemmatizer.lemmatize(word) for word in words]

vect = TfidfVectorizer(max_features=10000,stop_words=stop_words_,analyzer=split_into_lem

# Definición de variables predictoras (X)
X_dtm = vect.fit_transform(dataTraining['plot'])

# Definición de la variable respuesta (y)
X_test_dtm = vect.transform(dataTesting['plot'])
```

```
[nltk_data] Downloading package stopwords to
[nltk_data]     /Users/gabrielbga/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
[nltk_data] Downloading package wordnet to
[nltk_data]     /Users/gabrielbga/nltk_data...
[nltk_data]   Package wordnet is already up-to-date!
```

```
[nltk_data] Downloading package averaged_perceptron_tagger to
[nltk_data]     /Users/gabrielbga/nltk_data...
[nltk_data]   Package averaged_perceptron_tagger is already up-to-
[nltk_data]       date!
```

En primer lugar, probamos el eliminar los stopwords o palabras más comunes y esto mejoró la predicción del modelo. Seguidamente usamos lematización, proceso en el cual cada palabra se busca en un diccionario el cual ha sido previamente calculado y este, para cada palabra, nos va a decir cuál debe ser su representación. Usamos dos tipos de lematización, una que da la definición de la función para que tenga como parámetro texto y devuelva una lista de lemas, y el otro para lematizar los verbos en cada comentario. Los mejores valores se dieron con el primero por lo que solo documentamos este.

Para tokenizar los comentarios probamos los tokenizadores Count y TFID con valores por defecto. Los resultados mejoraron usando TFIDVectorizer en lugar de CountVectorizer. Esto es porque mientras que CountVectorizer simplemente cuenta el número de veces que aparece una palabra en un texto, TFID no solamente cuenta el número de veces sino que también evalúa que tan importante es la palabra en ese texto. Esto se hace gracias a la penalización de algunas palabras que el algoritmo considera menos importantes. Precisamente este factor es el que puede darle ventaja de TF-IDF sobre CountVectorizer, dado que, en resumen, este último pesa todas las palabras por igual, mientras que el primero ayuda a lidiar con las palabras más repetitivas y las penaliza.

En conclusión, usando la mayoría de técnicas de preprocesamiento, los mejores valores predictivos del modelo los encontramoso usando FIDVectorizer + Stop words + Lematización de verbos.

In [16]:
```
# Definición de variable de interés (y)
dataTraining['genres'] = dataTraining['genres'].map(lambda x: eval(x))
le = MultiLabelBinarizer()
y_genres = le.fit_transform(dataTraining['genres'])
y_genres
```

Out[16]:
```
array([[0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 1, 0, 0],
       ...,
       [0, 1, 0, ..., 0, 0, 0],
       [0, 1, 1, ..., 0, 0, 0],
       [0, 1, 1, ..., 0, 0, 0]])
```

In [17]:
```
# Convertir la matriz dispersa en una matriz densa de NumPy
X_dtm = X_dtm.toarray()
X_test_dtm = X_test_dtm.toarray()
```

In [18]:
```
# Separación de variables predictoras (X) y variable de interés (y) en set de entrenamie
X_train, X_test, y_train_genres, y_test_genres = train_test_split(X_dtm, y_genres, test_
```

In [19]:
```
#Guardamos en dims el número de dimensiones de la muestra train
dims = X_train.shape[1]
print(dims, 'input variables')
```

```
10000 input variables
```

In [20]:
```
#Guardamos en output_var el número de dimensiones de la muestra test
output_var = y_train_genres.shape[1]
print(output_var, ' output variables')
```

```
24  output variables
```

Definimos variables de interés, separamos la muestra en entrenamiento y evaluación para posteriormente calibrar y entrenar el modelo.

Calibración del modelo

Las redes neuronales pueden hacer muy facilmente overfitting con los datos de entrenamiento. Por lo que hacer split con data de validación, permite calibrar hiperparametros de la red y así hacer que el algoritmo logre generalizar todos los casos posibles.

In [21]:
```
X_train, X_val, Y_train, Y_val = train_test_split(X_train, y_train_genres, test_size=0.1
```

Definimos una función nn_model_params que crea una red neuronal a partir de 7 diferentes parámetros a calibrar:

In [22]:
```
def nn_model_params(optimizer,
                    neurons,
                    batch_size,
                    epochs,
                    activation,
                    patience,
                    loss):

    K.clear_session()
    model = Sequential()
    model.add(Dense(neurons, input_shape=(dims,), activation=activation))
    model.add(Dense(neurons, activation=activation))
    model.add(Dense(output_var, activation=activation))
    model.compile(optimizer = optimizer, loss=loss)
    early_stopping = EarlyStopping(monitor="val_loss", patience = patience)
    model.fit(X_train, Y_train,
              validation_data = (X_val, Y_val),
              epochs=epochs,
              batch_size=batch_size,
              callbacks=[early_stopping, PlotLossesKeras()],
              verbose=True
              )

    return model
```

In [15]:
```
nn_params = {
    'optimizer': ['adam','sgd'],
    'activation': ['sigmoid'],
    'batch_size': [64,128],
    'neurons':[64,256],
    'epochs':[20,50],
    'patience':[2,5],
    'loss':['binary_crossentropy']
}
```

Método busqueda por cuadrícula (Grid Search)

La búsqueda por cuadrícula es un método de calibración de parámetros donde se considera exhaustivamente todas las combinaciones de parámetros de un conjunto determinado.

In [16]:
```
nn_model = KerasRegressor(build_fn=nn_model_params, verbose=0)
gs = GridSearchCV(nn_model, nn_params, cv=3)
gs.fit(X_train, Y_train)
print('Los mejores parametros segun Grid Search:', gs.best_params_)
```

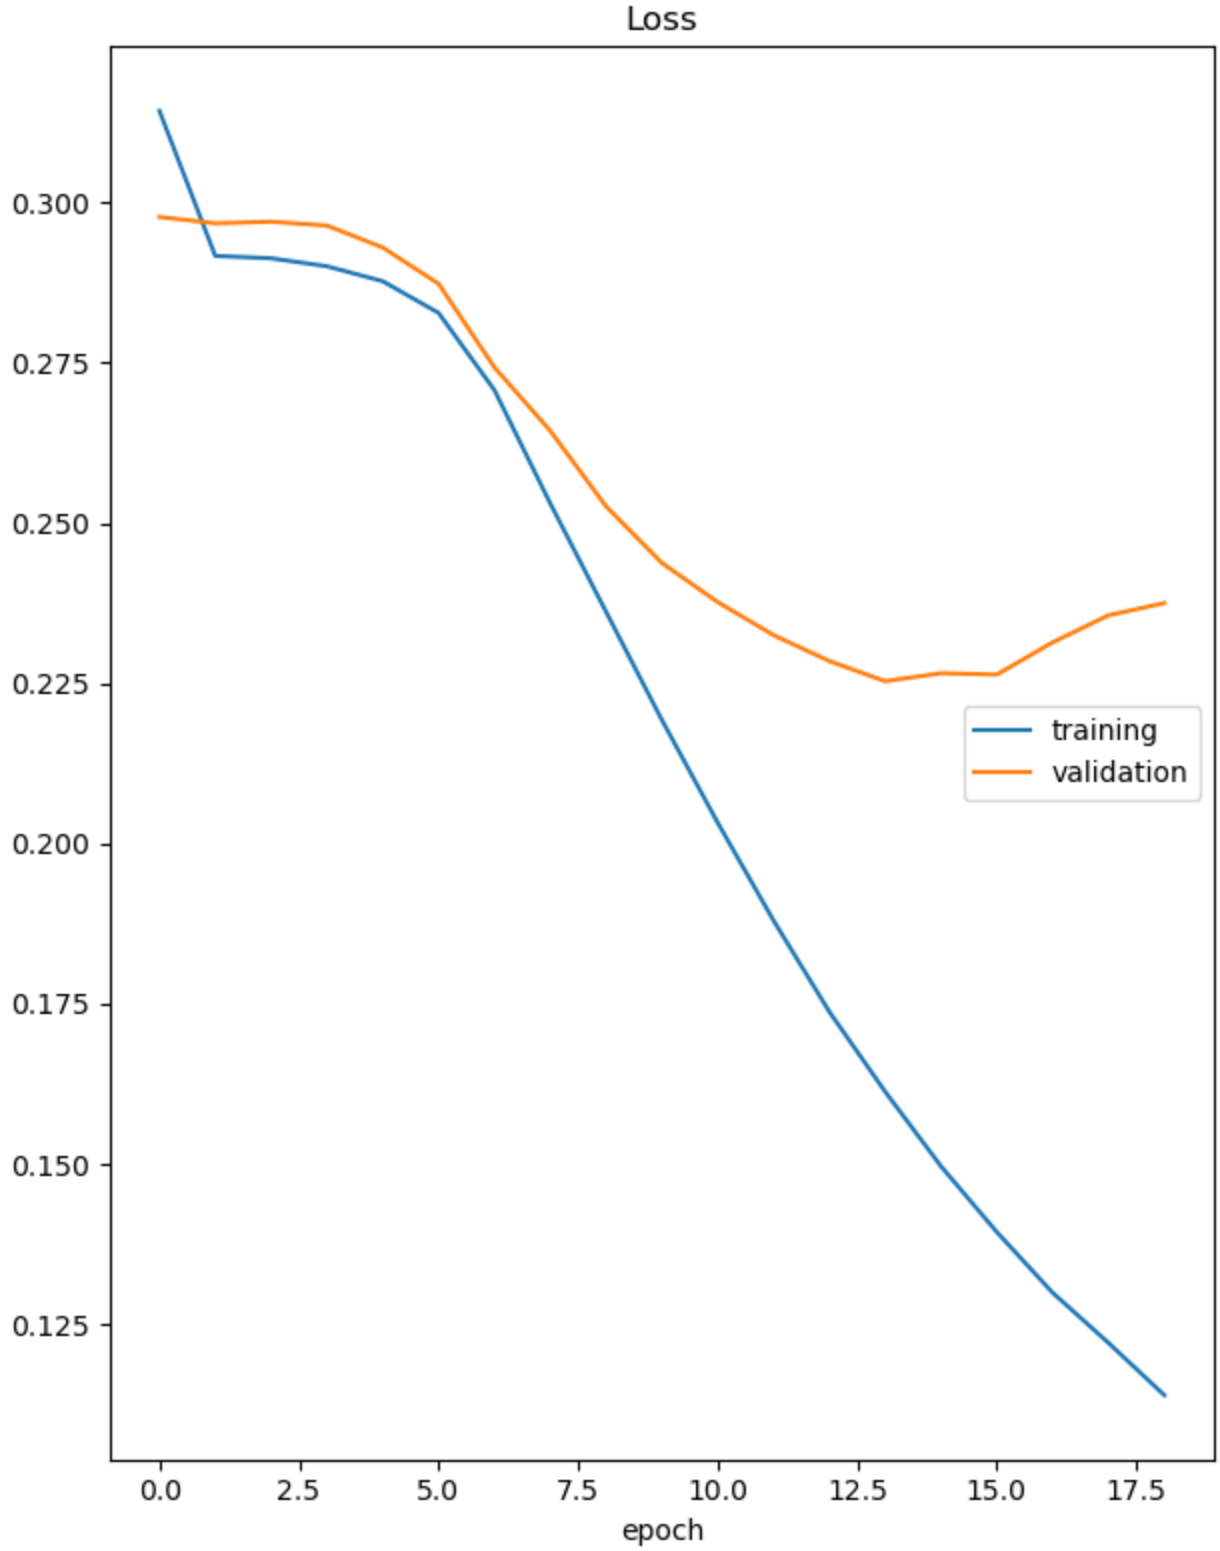


```
Loss
        training                (min:    0.114, max:    0.314, cur:    0.114)
        validation              (min:    0.225, max:    0.298, cur:    0.238)
71/71 [==============================] - 2s 32ms/step - loss: 0.1139 - val_loss: 0.2375
Los mejores parametros segun Grid Search: {'activation': 'sigmoid', 'batch_size': 64, 'e
pochs': 20, 'loss': 'binary_crossentropy', 'neurons': 256, 'optimizer': 'adam', 'patienc
e': 5}
```

En resumen, dado que las redes neuronales pueden hacer facilmente overfitting, partimos la muestra de nuevo para obtener train y test en validación y poder así generalizar todos los casos posibles.

Luego definimos una función para calibrar 7 hiperparámetros de una red neuronal y poder así encontrar los mejores valores.

Para la calibración de hiperparámetros el modelo Grindsearch, al considerar todas las combinaciones posibles, es un poco mejor que el Ramdonsearch dado que este último toma valores aleatorios y los evalúa. Por lo tanto, aunque sabemos que es más costoso computacionalmente, y lo fue, escogimos el Grindsearch para calibrar los hiperparámetros de la red neuronal.

Los mejores valores arrojados son un modelo de activación sigmoidea, la cuál al estar sus valores entre 0 a 1 se usa especialmente para modelos en los que tenemos que predecir la probabilidad, como en este caso.

De igual manera, 20 fueron las épocas más óptimas, que se explican como cada ciclo de corrección de propagación hacia atrás y hacia adelante para reducir las pérdida. Es curioso que aunque en la gráfica se observa que la función de pérdida no llegó a una estabilidad, los valores predictivos del modelo arrojados son decentes.

El batchsize es 64, este es el número de ejemplos que se introducen en la red para que entrene de cada vez. Al haber escogido el menor entre 64 y 128, este entrena más rápido al tener en memoria menor cantidad de datos.

Se usó una función de pérdida de binarycrossentropy que mide la presentación de un modelo cuyo rendimiento es la probabilidad en un rango entre 0 y 1.

Por último, 256 neuronas fueron las más óptimas y un optimizador Adam el cuál combina las ventajas de los algoritmos RMSprop y Momentum para mejorar el proceso de aprendizaje de un modelo.

Entrenamiento del modelo

Entrenamos el modelo con los mejores parámetros que nos brindó la calibración usando un modelo de Grindsearch.

In [23]:
```
model = nn_model_params(optimizer = 'adam',
                        neurons=256,
                        batch_size=64,
                        epochs=20,
                        activation='sigmoid',
                        patience=5,
                        loss='binary_crossentropy')

model.fit(X_train, Y_train, validation_data = (X_val, Y_val), workers=6)
```

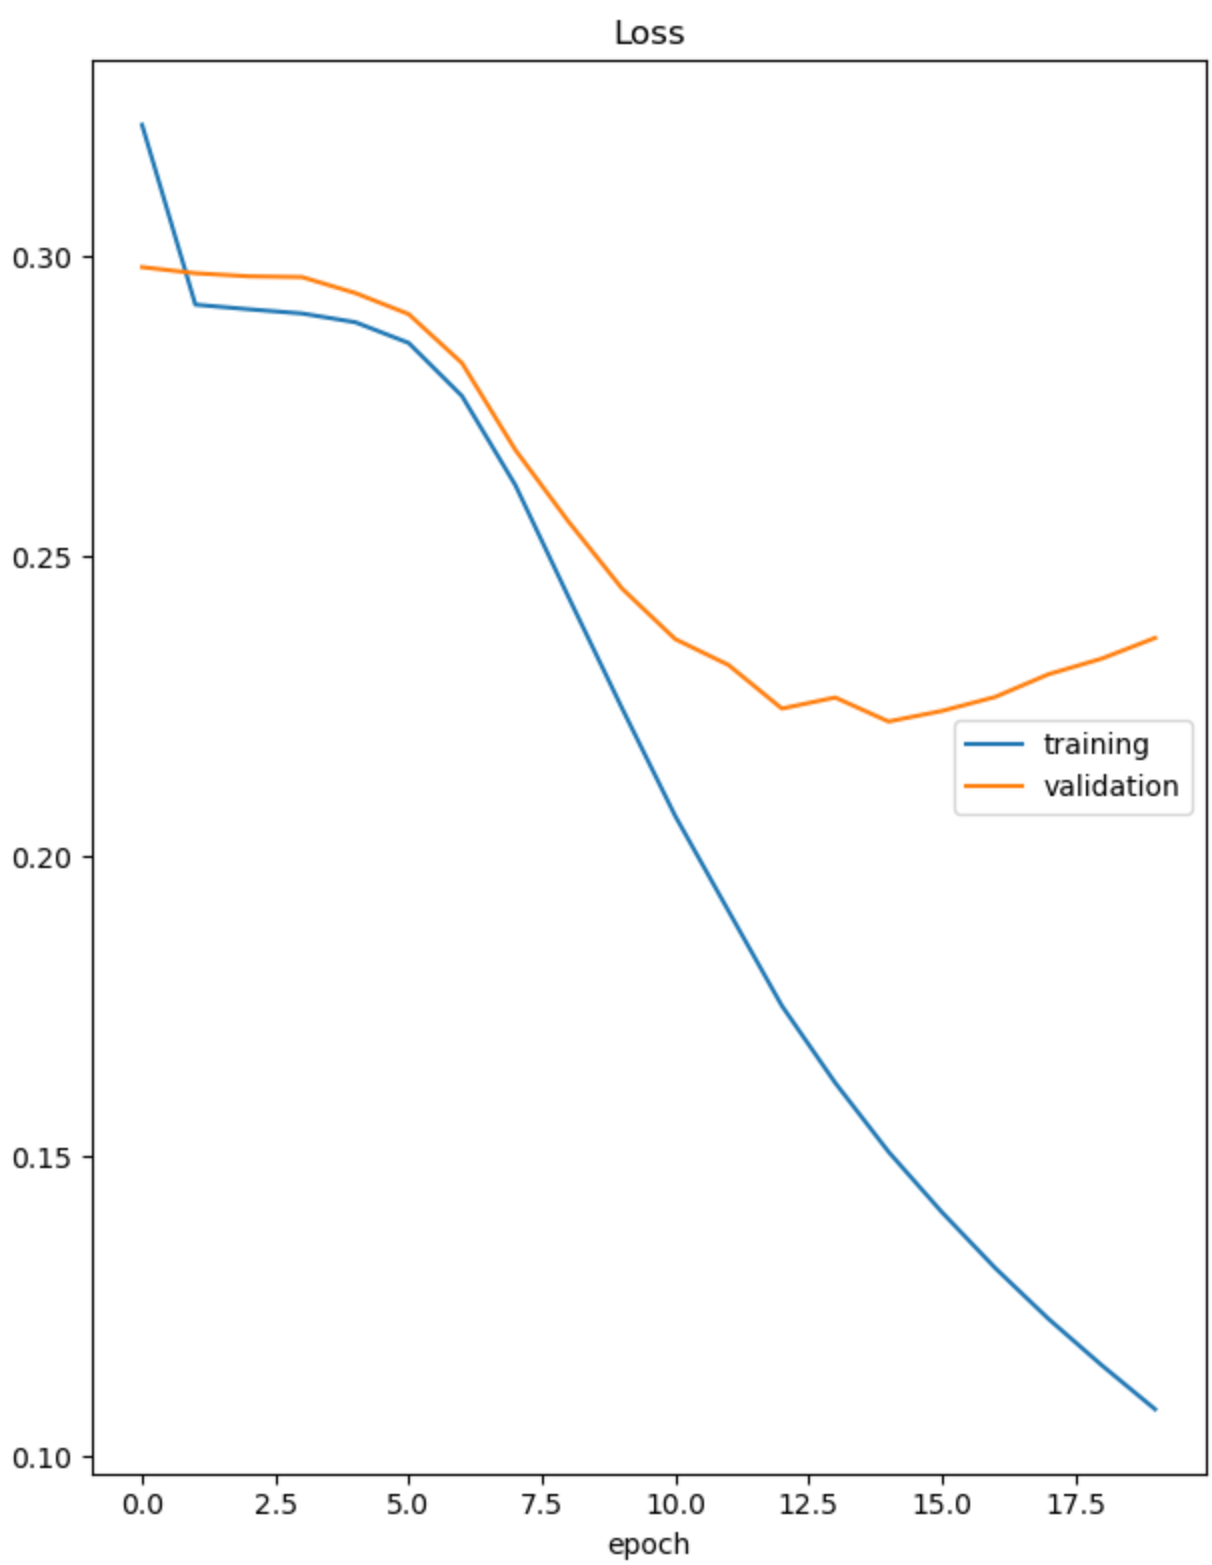


```
Loss
        training                 (min:    0.108, max:    0.322, cur:    0.108)
        validation               (min:    0.222, max:    0.298, cur:    0.236)
71/71 [==============================] - 1s 9ms/step - loss: 0.1078 - val_loss: 0.2364
141/141 [==============================] - 1s 5ms/step - loss: 0.1010 - val_loss: 0.2456
```

Out[23]:
```
<keras.src.callbacks.History at 0x2a0d47700>
```

In [24]:
```
y_pred_genres = model.predict(X_test)
roc_auc_score(y_test_genres, y_pred_genres, average='macro')
```

```
82/82 [==============================] - 0s 1ms/step
```

Out[24]:
```
0.8409607383756773
```

Evaluamos el desempeño del modelo en Xtest con la función predict usando la métrica de área bajo la curva

AUC. El valor arrojado es de 0.84, el cuál es un valor muy parecido al alcanzado en la competencia de Kaggle cuando el algoritmo se enfrentó a valores nuevos. Esta métrica proporciona una medida de rendimiento en todos los umbrales de clasificación posibles.

Escogimos como modelo de predicción las redes neuronales, dado que además de ser modelos que tienen el objetivo de encontrar la función que mejor se aproxime a un conjunto de datos, son capaces de aproximar funciones complejas, no necesariamente lineales, debido a que tienen un mayor poder de predicción.

Disponibilización del Modelo

Para disponibilizar el modelo a través de una api, es necesario exportar los archivos binarios de los modelos entrenados. Para este caso en particular, exportamos el modelo entrenado ***'model'*** que realizara las clasificaciones de los generos de las peliculas. Y además exportamos el modelo entrenado con los datos de training TfIdfVectorizer llamado ***'vect'*** que utilizaremos para transformar los datos desconocidos por el modelo en el argumento de entrada '*plot*' para que este los pueda entender y sea capaz de clasificar la información.

Una vez con los modelos exportados implementamos los siguientes pasos para disponibilizar el modelo:

1. Desde la consola de AWS lanzamos una Instancia **EC2** con SO **Ubuntu**.
2. Asignamos a la instancia los grupos de seguridad adecuados que permitan trafico de entrada desde **cualquier dirección IP** (0.0.0.0/0) y las definimos de tipo **TCP** por los **puertos 22, 446, 8888 y 5000**.
3. Utilizando el par de llaves publico-privada nos conectamos por **ssh** y subimos los archivos:

    - **_vect_gender_movies.pkl_**: Binario del modelo vectorizador.
    - **_clf_gender_movies.h5_**: Binario del modelo Clasificador.
    - ***api.py***: Script de python que levanta una API utilizando el framework de Flask. En este se hace una definición del *PATH* y tipo de petición (*GET* para este caso) y de los parametros que recibirá la API tales como '*year, title, plot*' y se agrega una descripción de ayuda al usuario para que pueda utilizarla claramente a través de la firma creada en formato swagger.json
    - **_model_deployment.py**: *Script de python que carga los modelos y define la funcion* **'clf_gender_movie(year, title, plot)'**_ que es llamada por la API

4. Levantamos la API y la dejamos ejecutandose en segundo plano utilizando el comando:
    - ***screen -d -m python3 api.py***

Se puede acceder a la firma de la API a través del siguiente link:

http://ec2-35-92-115-9.us-west-2.compute.amazonaws.com:8888

Probando modelo disponible a través de API en un EC2 en AWS

Una vez desplegado el servicio de EC2 en AWS y cargado los scripts descritos anteriormente procedemos a hacer un par de pruebas con la API, utilizando el DNS publico de la instancia y llamandolo por medio de comandos python para obtener una respuesta tipo JSON e imprimirla.

Realizaremos tres pruebas para demostrar su funcionamiento basada en los tres primeros registros del dataset de Testing:

Es importante aclarar que para poder consumir la API los espacios deben reemplazarse por su caracter correspondiente como %20.

In [26]:
```
import requests
import re

# Primera prueba ID 0
ruta_base = 'http://ec2-35-92-115-9.us-west-2.compute.amazonaws.com:8888/classifier/?'
year = 'year=' + str(dataTesting.iloc[0,:]['year'])
title = '&title=' + re.sub(' +', '%20',str(dataTesting.iloc[0,:]['title']))
plot = '&plot=' + re.sub(' +', '%20',str(dataTesting.iloc[0,:]['plot']))
url = ruta_base + year + title + plot # URL del endpoint

response = requests.get(url) # Realiza la solicitud GET

if response.status_code == 200: # Verifica si la respuesta es exitosa (código 200)
    data = response.json() # Obtén el JSON de la respuesta
    #print(data) # Imprime el JSON
else:
    data = "Error"
    #print(f'Error al realizar la solicitud: {response.status_code}')

print(dataTesting.iloc[0,:])
data
```

```
year                                                 1999
title                                 Message in a Bottle
plot     who meets by fate ,  shall be sealed by fate ....
Name: 1, dtype: object
```

Out[26]:
```
[{'p_Action': 0.0013035286,
  'p_Adventure': 0.0153117254,
  'p_Animation': 0.0010849548,
  'p_Biography': 0.0049630883,
  'p_Comedy': 0.6932355165,
  'p_Crime': 0.0130637195,
  'p_Documentary': 6.5982e-06,
  'p_Drama': 0.9511572719,
  'p_Family': 0.0059937723,
  'p_Fantasy': 0.0923378989,
  'p_Film-Noir': 0.0099457996,
  'p_History': 0.002210544,
  'p_Horror': 0.004236877,
  'p_Music': 0.0096301688,
  'p_Musical': 0.0420891307,
  'p_Mystery': 0.0745066851,
  'p_News': 0.0005386724,
  'p_Romance': 0.9944974184,
  'p_Sci-Fi': 0.0022259071,
  'p_Short': 0.003241861,
  'p_Sport': 0.0015135703,
  'p_Thriller': 0.0178215913,
  'p_War': 0.0021817936,
  'p_Western': 0.0085275071}]
```

In [27]:
```
# Segunda prueba ID 1
ruta_base = 'http://ec2-35-92-115-9.us-west-2.compute.amazonaws.com:8888/classifier/?'
year = 'year=' + str(dataTesting.iloc[1,:]['year'])
title = '&title=' + re.sub(' +', '%20',str(dataTesting.iloc[1,:]['title']))
plot = '&plot=' + re.sub(' +', '%20',str(dataTesting.iloc[1,:]['plot']))
url = ruta_base + year + title + plot # URL del endpoint
```

```
response = requests.get(url) # Realiza la solicitud GET

if response.status_code == 200: # Verifica si la respuesta es exitosa (código 200)
    data = response.json() # Obtén el JSON de la respuesta
    #print(data) # Imprime el JSON
else:
    data = "Error"
    #print(f'Error al realizar la solicitud: {response.status_code}')

print(dataTesting.iloc[1,:])
data
```

```
year                                                 1978
title                                    Midnight Express
plot     the true story of billy hayes ,  an american c...
Name: 4, dtype: object
```

Out[27]:

```
[{'p_Action': 0.1902271658,
  'p_Adventure': 0.005834498,
  'p_Animation': 0.000260144,
  'p_Biography': 0.0070442497,
  'p_Comedy': 0.1507183015,
  'p_Crime': 0.5533950925,
  'p_Documentary': 0.0086294999,
  'p_Drama': 0.252417475,
  'p_Family': 0.0005664698,
  'p_Fantasy': 0.0014370566,
  'p_Film-Noir': 0.0096444543,
  'p_History': 0.0021165935,
  'p_Horror': 0.0423066318,
  'p_Music': 0.0022852526,
  'p_Musical': 0.0011836416,
  'p_Mystery': 0.0707583129,
  'p_News': 0.0007491773,
  'p_Romance': 0.001993811,
  'p_Sci-Fi': 0.0355842449,
  'p_Short': 0.0059541953,
  'p_Sport': 0.0048801024,
  'p_Thriller': 0.6760299206,
  'p_War': 0.0014415757,
  'p_Western': 0.0104586538}]
```

Conclusiones

En primer lugar, para el preprocesamiento los mejores resultados fueron la combinación de eliminar los stopwords o palabras más comunes, lematización para conocer la representación de cada palabra usando un diccionario y TFIDVectorizer que ayuda a lidiar con las palabras más repetitivas y las penaliza.

En la calibración de parámetros en primer lugar fue importante volver a dividir la muestra para combatir el overfitting y poder generalizar todos los casos posibles. Igualmente, aunque conocemos que ramdonsearch es un calibrador de hiperparámetros más rápido, preferimos usar Grindsearch dado que este evalúa todos los casos posibles. Sin embargo, sabemos que el valor computacional es muy alto y en próximos estudios es preciso evaluar estos métodos de nuevo, con más valores para mejorar la predicción del modelo. Esto se pudo observar claramente en la gráfica donde la función de pérdida no llegó a una estabilidad clara.

Escogimos como modelo de predicción las redes neuronales dado que tienen un mayor poder de predicción y son capaces de aproximar funciones complejas no necesariamente lineales.

El valor predictivo del modelo en entrenamiento y cuando se enfrentó a valores nuevos en la competencia de Kaggle fue muy parecido, casi igual. Por lo que se entiende que see combatió el problema de overfitting.

Por último, es importante resaltar que los valores predictivos del modelo se pueden mejorar en estudios futuros. Esto es calibrando mejor los hiperparámetros dado que por cuestiones de tiempo y que hacerlo es computacionalmente alto, no se pudo profundizar en este estudio.

In [ ]: